

ENTREGA DE PROTOCOLO

Optimización Estocástica y Teoría del Límite de Aprendizaje

Asignación 4: Análisis de Sesgo-Varianza y Métodos de Gradiente

Estudiante:

Víctor Manuel Ruiz Pereda

Fecha de Cierre:

10 de junio de 2026

Capítulo 4

Límites y Dinámicas de Optimización

4.1 Teorema de Descomposición del Error Cuadrático

Dentro del aprendizaje estadístico supervisado, el riesgo esperado de un regresor estimado puede descomponerse mediante componentes ortogonales algebraicos independientes:

$$\text{MSE} = \left(f(x) - \mathbb{E}[\hat{f}(x)] \right)^2 + \mathbb{E} \left[\left(\hat{f}(x) - \mathbb{E}[\hat{f}(x)] \right)^2 \right] + \sigma^2$$

Este compromiso balanceado describe las limitaciones de los modelos: un modelo con baja capacidad matemática presentará un sesgo alto por la falta de ajuste estructural, mientras que un modelo sobre-parametrizado capturará las fluctuaciones aleatorias de la muestra, disparando la varianza y perdiendo robustez ante datos no observados durante el entrenamiento.

4.2 Mecánica Dinámica del Descenso de Gradiente Estocástico

El algoritmo del Descenso de Gradiente Estocástico (SGD) aproxima el vector de actualización evaluando la pérdida sobre una única muestra aleatoria en lugar del conjunto de datos completo:

$$\theta_{t+1} = \theta_t - \alpha \nabla_{\theta} \mathcal{L}_i(\theta_t)$$

Esta naturaleza aleatoria rompe la trayectoria monótona del descenso analítico tradicional. El ruido estocástico inducido en el gradiente funciona como una fuerza regularizadora dinámica, permitiendo que los parámetros del sistema escapen de configuraciones atrapadas en mínimos locales poco profundos hacia valles de optimización con mayor capacidad de generalización.